Do Consumo de Energia ao Ciclo de Vida: Definição, Medição e Redução do Impacto Ambiental da Inteligência Artificial

Nome do Autor

[1] Endereço

Abstract. *This paper synthesizes thirteen recent reviews on Green AI to examine how the environmental impact of artificial intelligence is defined, measured and reduced. The analysis shows that the definition has moved from training energy to a full life-cycle footprint that includes hardware, water and social justice, and that a reduction only counts if it is net, absolute and measured within declared boundaries. Techniques at the data, model, hardware and operational levels are compared, and the main bottlenecks (inconsistent boundaries, proxy metrics, second-hand evidence and rebound effects) are discussed. Future directions center on standardized reporting, mandatory life-cycle assessment and absolute caps.*

Resumo. *Este artigo sintetiza treze revisões recentes sobre Green AI para examinar como o impacto ambiental da inteligência artificial é definido, medido e reduzido. A análise mostra que a definição migrou da energia do treinamento para uma pegada de ciclo de vida completo, que inclui hardware, água e justiça social, e que uma redução só é válida se for líquida, absoluta e medida em fronteiras declaradas. São comparadas técnicas nos níveis de dados, modelo, hardware e operação, e discutidos os principais gargalos (fronteiras inconsistentes, métricas indiretas, evidência de segunda mão e efeito rebote). As direções futuras giram em torno de relato padronizado, avaliação de ciclo de vida obrigatória e tetos absolutos.*

1. Introdução

O uso de inteligência artificial (IA) eleva o consumo de eletricidade, de emissões de carbono e de demanda por água e materiais da infraestrutura que a sustenta [Rajath and Vishwas Vivian 2026, Różycki et al. 2025, Lal and You 2025]. A literatura responde com o conceito de *Green AI*, que se contrapõe à *Red AI*, orientada apenas ao desempenho [Rajath and Vishwas Vivian 2026, Bayoumi et al. 2026, Peykani et al. 2026]. Apesar do volume de revisões e dos trabalhos usados em cada, não há consenso sobre o que significa "reduzir" o impacto, nem sobre como medi-lo de forma comparável.

Este trabalho reúne treze revisões publicadas entre 2023 e 2026 e busca responder três perguntas: (i) como o impacto ambiental da IA é definido e como essa definição mudou; (ii) como ele é medido; e (iii) que técnicas são propostas para reduzi-lo.

2. Método

Inicialmente, usando a *string de busca "Green AI"*, na base de dados *Scopus*, foram selecionados, com data de corte em setembro de 2026, todas as revisões que apresentavam o termo *"Green AI"* no Título, *Abstract*, ou como palavra chave; resultando em 43 trabalhos. Desses, apenas 13 tratavam, de forma inequívoca, sobre *"Green AI"*. Por exemplo,

embora o trabalho [Rojek et al. 2024] estivesse contido entre os 43 iniciais, ele não trata a *Green AI* no sentido estrito de tornar o treinamento dos modelos de IA mais eficientes ou reduzir a pegada de água/carbono, mas sim em usar IA como uma ferramenta para ajudar fábricas e indústrias de manufatura a economizarem energia e gerenciarem seus recursos de forma mais limpa.

Das 13 revisões analisadas, a maioria é sistemática (PRISMA), algumas são narrativas ou conceituais [Różycki et al. 2025, Frimpong 2025, Naser 2026] e uma é prospectiva [Lal and You 2025]. Ademais, nenhuma delas realiza medições próprias de energia visto que os números de redução são apurados dos estudos analisados. Por isso, os valores apresentados neste artigo são *resultados relatados* pelas revisões, com tarefas, linhas de base e métricas distintas, e não devem ser somados.

3. Evolução da Definição de Impacto Ambiental da IA

3.1. Além da eficiência energética: a pegada ambiental

Em [Verdecchia et al. 2023] os autores definem Green AI como um conjunto de práticas que usam IA para mitigar o impacto humano sobre os recursos naturais e/ou mitigam o impacto da própria IA. Nesse estudo, os autores analisaram 98 estudos sobre Green AI, porém, 81 deles tratam apenas sobre reduzir o consumo de energia, o que os autores classificam como uma visão simplista, já que a IA utiliza recursos naturais heterogêneos, além do energético.

3.2. Perspectivas recentes: hardware, infraestrutura e justiça ambiental

Em 2025, surgem três abordagens complementares que ampliam o escopo da Green AI. A primeira foca no hardware e no seu ciclo de vida (desde a produção até a sua aposentadoria), apontando que o carbono embutido na fabricação pode superar o operacional, com estimativas superiores a 70 vezes para equipamentos de TI [Różycki et al. 2025]. A segunda desloca o foco do modelo para a infraestrutura e o sistema elétrico, alertando para o risco de dependência de combustíveis fósseis devido ao fato de o crescimento da demanda por energia superar a expansão de fontes limpas [Lal and You 2025]. A terceira abordagem integra otimização técnica, resultados ecológicos e responsabilidade social, abrangendo água, minerais, resíduos eletrônicos e a distribuição desigual de danos entre os países em desenvolvimento — que geralmente produzem matérias-primas — e os países desenvolvidos [Frimpong 2025].

3.3. O ciclo de vida se estende

Em [Naser 2026] o autor avalia o impacto ao longo de todo o ciclo de vida de modelos, software e hardware, destacando fatores como a permanência de versões desatualizadas em execução, a obsolescência em cascata de equipamentos e a necessidade prévia de questionar se o uso da IA é realmente indispensável.

3.4. Efetividade, fronteiras e escopo da redução

Em 2026 as revisões mudam a questão central de quanto se reduz para saber quando a redução é efetiva. Os autores em [Rojahn and Grum 2026] definem Green AI como sistemas com impactos acumulados menores dentro de fronteiras e ciclo de vida declarados,

mantendo o desempenho. Em [Khan et al. 2026] e [Oliveira et al. 2026] os autores distinguem a redução relativa (por tarefa) da redução absoluta (no consumo total), alertando para o risco do efeito rebote, visão reforçada em [Marmouzi et al. 2026] ao separarem Green, Sustainable, Responsible e Ethical AI. Além disso, em [Peykani et al. 2026] os autores tratam Red AI (prioriza exclusivamente o desempenho do modelo em detrimento do custo computacional e energético) e Green AI como um espectro contínuo e propõem avaliar carbono e água em conjunto, enquanto em [Alobid and Szűcs 2026] os autores diferenciam a retirada de água do seu consumo, bem como a pegada operacional (gerada durante a utilização) da incorporada (relativa à fabricação e ao descarte do hardware). Por fim, em [Rajath and Vishwas Vivian 2026] e [Bayoumi et al. 2026] os autores reforçam que a eficiência é necessária, mas insuficiente.

Em síntese, a evolução conceitual deslocou o foco da mera *energia de treinamento* (2023) para a ampliada de *hardware, infraestrutura e justiça ambiental* (2025), avançando para a consideração do *ciclo de vida completo e obsolescência* (2025/2026). Por fim, o estado atual exige que qualquer métrica de *redução seja líquida, absoluta, fundamentada em fronteiras declaradas, comparável e multidimensional* (2026).

4. Como o Impacto é Medido

A medição do impacto ambiental da IA baseia-se predominantemente no cálculo da pegada de carbono operacional, definida pela multiplicação do consumo energético pela intensidade de carbono da rede elétrica e corrigida pelo indicador de eficiência da infraestrutura (PUE) do *data center* [Różycki et al. 2025, Khan et al. 2026, Bayoumi et al. 2026, Peykani et al. 2026]. Em função das diferenças na matriz energética local, a execução de uma mesma carga computacional pode gerar variações de emissões de 5 a 30 vezes a depender da região geográfica [Różycki et al. 2025, Khan et al. 2026, Bayoumi et al. 2026]. Na literatura, os instrumentos de avaliação são divididos em três famílias principais: estimadores baseados em tempo e potência nominal (TDP); monitores em tempo de execução via *telemetria* (tecnologia que mede e coleta dados de um equipamento) de hardware (como interfaces RAPL e NVML); e metodologias de Avaliação do Ciclo de Vida (ACV) [Rajath and Vishwas Vivian 2026, Bayoumi et al. 2026, Peykani et al. 2026, Rojahn and Grum 2026]. Entre as ferramentas mais utilizadas destacam-se o CodeCarbon, Carbontracker, eco2AI e o Experiment Impact Tracker [Rajath and Vishwas Vivian 2026, Bayoumi et al. 2026, Peykani et al. 2026, Rojahn and Grum 2026]. Para o consumo hídrico, utiliza-se a métrica WUE (*Water Usage Effectiveness*), distinguindo-se o uso local (refrigeração direta das instalações) do uso fora do local (associado à geração de eletricidade na rede) [Peykani et al. 2026, Alobid and Szűcs 2026].

Um ponto crítico enfatizado nas revisões é que indicadores indiretos (*proxies*) não equivalem ao consumo energético real: métricas como $FLOPs$, quantidade de parâmetros, GPU-horas, tempo de execução e uso de memória mensuram apenas o esforço computacional ou a estrutura do modelo [Marmouzi et al. 2026, Frimpong 2025, Peykani et al. 2026, Rojahn and Grum 2026, Naser 2026]. Da mesma forma, a energia medida não equivale diretamente às emissões de carbono, e o carbono operacional não substitui uma ACV completa (que inclui a fabricação e o descarte do hardware). Diante disso, em [Rojahn and Grum 2026] os autores propõem um protocolo de calibração que ajusta estimativas teóricas a medições físicas diretas (colhidas na tomada, no *rack* ou via

sensores internos), ressaltando que a medição direta se limita estritamente à fronteira que foi efetivamente medida.

5. Síntese e Comparação de Técnicas

A Tabela 1 resume as técnicas por camada. Os percentuais são os relatados pelas revisões.

Tabela 1. Técnicas de redução, resultados relatados e ressalvas

Camada	Técnica	Resultado relatado	Variável medida / ressalva
Dados	Modificação e aumento de dados, seleção de atributos, subamostragem	Até 92% de energia [Rajath and Vishwas Vivian 2026, Verdecchia et al. 2023]	Fonte única; instrumentação não descrita
Dados	Destilação de conjuntos de dados	40–60% menos iterações [Marmouzi et al. 2026]	Iterações, não energia
Modelo	Poda	−42% [Khan et al. 2026]; 20–50% com suporte à esparsidade [Peykani et al. 2026]	Só rende se o hardware explora a esparsidade
Modelo	Quantização	−31% [Khan et al. 2026]; 30–60% [Peykani et al. 2026]; até 94% por operação de 32 para 8 bits [Bayoumi et al. 2026]	Por operação, inferência ou memória, conforme o estudo
Modelo	Destilação de conhecimento	−25% [Khan et al. 2026]; fator 19 [Różycki et al. 2025]; fator 3–5 na inferência [Marmouzi et al. 2026]	Custo do professor costuma ficar de fora
Modelo	Parada antecipada, ajuste de hiperparâmetros, NAS	Até 80% [Różycki et al. 2025, Naser 2026]; NAS com 70–80% menos experimentos [Peykani et al. 2026]	Número de experimentos e R^2 do preditor não são energia
Software	Bibliotecas de dados (Pandas, Polars, PySpark)	60% de potencial [Khan et al. 2026]; sem percentual em [Oliveira et al. 2026]	Benchmark dependente da carga de trabalho
Hardware	TPU, ASIC, FPGA	TPU 20–30% melhor que GPU [Rajath and Vishwas Vivian 2026]; 15–50× em ASICs [Marmouzi et al. 2026]	Razão de eficiência, sem carbono embutido
Hardware	Efeito ajustado ao ciclo de vida	−24,8% cai para −12,3% [Khan et al. 2026]	Mostra o peso da fabricação
Hardware	Borda, computação em memória	∼70% menos energia de transmissão [Marmouzi et al. 2026]	Comparações pontuais; a borda desloca consumo
Operação	Agendamento e localização cientes de carbono	30–50% [Khan et al. 2026]; 15–30% [Marmouzi et al. 2026]	Reduz carbono, não necessariamente kWh
Operação	Refrigeração líquida e por imersão	Até ∼90% (refrigeração); imersão 62,9–80% [Alobid and Szűcs 2026]	Modelado ou de fornecedor; não é a energia total
Operação	Serving (lotes, cache, roteamento), limite de potência	Cache ∼50% de ciclos; limite de potência 12–15% por 3% de tempo [Naser 2026]; 33× por prompt em um operador [Alobid and Szűcs 2026]	Uma empresa, sem auditoria independente
Governança	Relato, ACV, auditoria, tetos	Sem redução medida [Khan et al. 2026, Oliveira et al. 2026, Frimpong 2025, Alobid and Szűcs 2026]	Condição de verificabilidade, não economia

5.1. Camada de dados

São técnicas que atuam sobre os dados e não sobre o modelo.

1. Modificação e aumento de dados, seleção de atributos e subamostragem. Uma modificação no conjunto de dados é feita por meio de sua limpeza e pré-processamento. Isso elimina redundâncias, reduz o número de atributos e seleciona amostras que obedecem a esses critérios [Rajath and Vishwas Vivian 2026]; o filtro dos atributos e seleção de uma subamostragem são responsáveis por remover dados que possuem baixa contribuição para o aprendizado, e há estratégias capazes de remover pontos de dados que são esperados como redundantes [Verdecchia et al. 2023]. Ademais, é útil aumentar o número de dados, gerando versões alteradas dos exemplos que já existem com

o objetivo de melhorar a generalização e reduzir a coleta e rotulação de mais dados; a principal desvantagem desse método é que ele pode introduzir variações nas predições e reduzir a acurácia [Rajath and Vishwas Vivian 2026]. Essas técnicas têm por objetivo reduzir o treinamento e, consequentemente, seu custo, utilizando menos dados e dados melhores.

2. Destilação de conjuntos de dados. É a criação de um conjunto sintético, com menos dados, que é capaz de preservar as principais características do conjunto original [Rajath and Vishwas Vivian 2026]. O treinamento do modelo é feito utilizando essa representação reduzida, o que diminui o número de iterações de treinamento (entre 40 a 60 por cento a menos nos estudos feitos) [Marmouzi et al. 2026]. É importante ressaltar que há custo para construir o conjunto destilado; esse custo deve entrar no balanço, e nem sempre o ganho em iterações é transformado em ganho energético.

5.2. Camada de modelo

São técnicas que atuam diretamente nos modelos.

3. Poda. É usada para remover parâmetros ou estruturas que têm baixa contribuição. Existem três tipos de poda (não estruturada, estruturada e dinâmica): a poda não estruturada elimina pesos de forma individual, geralmente aqueles com valor próximo de zero; a estruturada pode eliminar neurônios, canais ou camadas inteiras, o que é mais amigável para o hardware; a dinâmica é uma poda feita durante o treinamento [Bayoumi et al. 2026, Naser 2026]. Ademais, existe a busca de sub-redes, mais eficazes, por *lottery tickets* e *rewinding*, o que evita fazer várias rodadas de poda e retreinamento [Naser 2026]. O ganho econômico é possível pela redução das operações e dos acessos à memória, entretanto, só é efetivo se o hardware for capaz de explorar a esparsidade resultante [Peykani et al. 2026]. Em contrapartida, é possível ter perdas na acurácia e no retreinamento.

4. Quantização. É utilizada para reduzir a precisão numérica usada para representar pesos, por exemplo, de 32 bits (FP32) para INT8 ou INT4 [Bayoumi et al. 2026, Peykani et al. 2026, Naser 2026]. Existem duas abordagens possíveis: a quantização pós-treinamento, que é mais barata e que utiliza calibração com amostras representativas; o treinamento consciente da quantização, que é responsável por simular uma baixa precisão durante o treino, preservando a melhor acurácia [Bayoumi et al. 2026, Naser 2026]. O menor número de bits diminui o volume de dados que trafega na memória e gera contas aritméticas mais baratas [Bayoumi et al. 2026]. A economia depende do hardware suportar operações de baixa precisão e de que a acurácia seja preservada [Peykani et al. 2026, Naser 2026].

5. Destilação de conhecimento. É a utilização de um modelo professor grande, isto é, um modelo já treinado que transfere seu comportamento a um modelo aluno menor, usado na inferência [Rajath and Vishwas Vivian 2026, Bayoumi et al. 2026]. O modelo professor é capaz de fornecer probabilidades suaves e a transferência de comportamento pode ser calcada em resposta, em características intermediárias ou nas relações entre as amostras [Bayoumi et al. 2026]. Isso faz com que o aluno exija menos memória e cálculo por resposta, o que é acumulado em milhões de inferências [Bayoumi et al. 2026]. Em contrapartida, a eficiência depende de ter um professor qualificado e do custo de treinamento do professor e do aluno [Bayoumi et al. 2026, Marmouzi et al. 2026].

6. Parada antecipada, ajuste de hiperparâmetros e NAS. São técnicas que reduzem o custo da *busca* pelo modelo. A parada antecipada é útil para interromper treinamentos quando o ganho em desempenho se estabiliza ou atinge um limiar, o que evita novos ciclos de treinamento sem ganho [Różycki et al. 2025], o que também possibilita o descarte de candidatos que possuem baixo desempenho na otimização de hiperparâmetros [Naser 2026]. No ajuste bayesiano, são usados modelos probabilísticos capazes de explorar o espaço de hiperparâmetros que possuem menos avaliações [Różycki et al. 2025]. A busca de arquiteturas neurais (NAS) é responsável por automatizar a escolha de topologias que combinam qualidade, FLOPs, memória, latência e energia, e utiliza preditores capazes de rejeitar arquiteturas antes do treinamento completo [Peykani et al. 2026, Naser 2026]. É importante contabilizar tanto o custo do preditor quanto o de toda a busca.

5.3. Camada de software

São técnicas que atuam a nível de software.

7. Bibliotecas de dados. É feita uma intervenção na fase de preparação e movimentação dos dados, isto é, antes do modelo, ao escolher entre bibliotecas como Pandas, Polars e PySpark, que são responsáveis por organizar paralelismo, memória e a execução de formas diferentes [Khan et al. 2026, Oliveira et al. 2026]. O método identificado é o *benchmark*, que faz um comparativo de tempo, carga de CPU e energia [Oliveira et al. 2026]. A mesma ideia surge quando há comparações entre *frameworks* de aprendizado profundo; entretanto, as revisões divergem em qual é mais eficiente em treino e em inferência [Bayoumi et al. 2026, Verdecchia et al. 2023]. A escolha da biblioteca vencedora depende do contexto, não tendo uma que vença todos [Oliveira et al. 2026].

5.4. Camada de hardware

Nessa camada aborda estratégias de uso de hardware especializado motiva redução da marca de carbono.

8. Processadores ASIC e FPGA. ASICs (*Application-Specific Integrated Circuits*), ou Circuitos Integrado de Aplicação Específica, dedicam circuitos e memória às operações de inteligência artificial, enquanto FPGAs (*Field-Programmable Gate Array*), ou Arranjos de Portas Programável em Campo, reconfiguram a lógica e os caminhos de dados [Naser 2026]. Ambos os hardwares são tipos de TPUs (*Tensor Processing Units*), ou Unidade de Processamento Tensorial, processadores que executam o trabalho recorrente com mais desempenho por watt do que processadores de uso geral [Rajath and Vishwas Vivian 2026, Lal and You 2025, Marmouzi et al. 2026]. O ganho real é uma razão de eficiência entre plataformas e não inclui o carbono da fabricação [Marmouzi et al. 2026] desses equipamentos, o que motiva a próxima linha.

9. Efeito ajustado ao ciclo de vida. É uma forma de avaliar o hardware e sua eficiência operacional em relação ao carbono da fabricação, amortizado pela vida útil do equipamento (emissão de fabricação $\times$ número de unidades $\times$ fração de amortização) [Khan et al. 2026]. Esse efeito agrupado do hardware cai de $-24{,}8\%$ para $-12{,}3\%$, porque são necessários de 2 a 5 anos de economia operacional para compensar a fabricação [Khan et al. 2026]. A avaliação do ciclo de vida dessas TPUs com uma métrica de computação da intensidade de carbono é um exemplo de aplicação [Oliveira et al. 2026].

10. Borda e computação em memória. A computação de borda é o onde acontece o processamento dos dados próximo de onde são gerados, o que ameniza a transmissão contínua à nuvem (cerca de 70% menos energia de transmissão) [Marmouzi et al. 2026, Peykani et al. 2026]. A computação em memória e processamento em memória aproximam as operações para perto da memória com objetivo de melhorar o tráfego entre processador e memória, com ganhos que vão de centenas de vezes a milhares em comparações específicas [Peykani et al. 2026, Naser 2026]. Assim, como a borda desloca consumo e fabricação para os dispositivos locais, essa descentralização altera os impactos incorporados [Marmouzi et al. 2026].

5.5. Camada de operação

Nessa seção, trazemos estratégias sobre planejamento de horário para uso, refrigeração por líquidos e otimização da execução dos modelos.

11. Agendamento e localização cientes de carbono. Observar como tarefas flexíveis no tempo, para janelas de maior oferta de energia renovável, e no espaço, para regiões de distribuição com fontes mais limpas [Khan et al. 2026, Marmouzi et al. 2026, Rojahn and Grum 2026] pode ser uma boa estratégia. Nesse sentido, observamos mais o carbono por kWh e não sobre o kWh consumido [Khan et al. 2026]. No entanto, necessita-se considerar prazos e níveis de serviço, custos de migração de dados e de pausa e retomada (*checkpointing*) [Rojahn and Grum 2026, Naser 2026], além do risco de "vazamento de carbono", quando o treinamento dos modelos aproveitou mais de energia limpa, ao passo que a execução do serviço usou mais de rede fóssil [Khan et al. 2026]. Além disso, devemos considerar que esses *datacenters* dissipam muito calor.

12. Refrigeração líquida e por imersão. Essa estratégia é considerar a refrigeração desses servidores com líquido em vez de ar, onde a refrigeração direta ao chip possuiria líquido circulante junto ao componente, e em uma configuração para imersão monofásica, os componentes ficam mergulhados em fluido [Peykani et al. 2026, Alobid and Szűcs 2026]. Os indicadores de eficiência de uso de energia e de uso de água observam como a refrigeração evaporativa, por exemplo, reduz energia de refrigeração, mas eleva o consumo de água [Alobid and Szűcs 2026]. Assim, os ganhos relatados vêm de simulação, pilotos e dados de fornecedores, mas não são a energia total do data center e deixam de fora fluidos, fabricação e manutenção [Alobid and Szűcs 2026].

13. Serving e limite de potência. Talvez uma das melhores estratégias pensadas pode ser otimizar a fase de inferência (*serving*) em ambiente de produção. A etapa de inferência de inteligência artificial combina os agrupamentos de requisições (lotes), cache de resultados e ativações, roteamento entre hardware heterogêneo e multi-locação para preencher ciclos ociosos [Naser 2026] de uso. Enquanto isso, o limite de potência (*power capping*) impõe um teto de consumo e troca energia por tempo, com 12–15% menos energia e 3% mais tempo de conclusão [Rojahn and Grum 2026, Naser 2026]. Portanto, o resultado de 33$\times$ por *prompt* vem de um único operador, combina melhorias do modelo e da utilização e não foi auditado de forma independente [Alobid and Szűcs 2026].

5.6. Camada de governança

Nessa camada, observamos três aspectos de observabilidade de medições e fiscalizações da operação e treinamento de inteligência artificial.

14. Relato, Avaliação do Ciclo de Vida, auditoria e tetos. Abordar possíveis reduções verificáveis. Propondo mecanismos como o relato obrigatório em cinco categorias de divulgação e três níveis de conformidade (Protocolo de Contabilização de Carbono para IA Sustentável) [Khan et al. 2026], a divulgação auditada e a certificação independente para sistemas acima de um limiar de computação [Frimpong 2025], Avaliação do Ciclo de Vida padronizada [Frimpong 2025], os orçamentos de sustentabilidade que limitam energia ou carbono por projeto [Oliveira et al. 2026] e os limites absolutos de retirada de água [Alobid and Szűcs 2026]. Logo, essas revisões não atribuem às medições uma real redução, mas a transparência motiva a alteração e busca por melhores processos de decisões [Oliveira et al. 2026, Frimpong 2025, Alobid and Szűcs 2026].

5.7. Padrões da comparação

É notável que o maior rendimento advém dos dados (até 92%) e da compressão de modelos, e a única estimativa agregada com meta-análise é de $-38{,}2\%$ para a otimização algorítmica, $-24{,}8\%$ para hardware e $-29{,}7\%$ para operação, com $-32{,}4\%$ para o conjunto [Khan et al. 2026]. Além disso, as camadas observadas atuam em fatores diferentes, quando o algoritmo reduz kWh, o hardware reduz energia por operação e a operação reduz carbono por kWh, por isso se complementam [Khan et al. 2026]. No entanto, escolher o algoritmo mais simples que resolve a tarefa também é uma redução considerável, pois modelos clássicos gastam muito menos energia que àqueles que usam arquiteturas Transformers [Różycki et al. 2025]. Assim, Khan et al. recomendam esgotar primeiro a compressão algorítmica e só depois o hardware [Khan et al. 2026].

6. Análise Crítica e Gargalos

6.1. Gargalos de medição

Há uma inconsistência entre as fronteiras; as estimativas variam de acordo com o que entra na conta; a maioria dos estudos não leva em conta a inferência e não leva em conta o carbono embutido [Khan et al. 2026]. Além disso, existe uma diferença na medição da intensidade média anual e na marginal da rede, e uma diferença na alocação em nuvem multiusuário [Khan et al. 2026]. Muitos trabalhos não discutem sobre hardware ou intervalos de confiança [Khan et al. 2026, Marmouzi et al. 2026], e somente alguns estudos disponibilizam ferramentas [Verdecchia et al. 2023]. Em muitos casos, proxies são tratados como energia [Różycki et al. 2025, Bayoumi et al. 2026, Verdecchia et al. 2023].

6.2. Gargalos de evidência

Muitos resultados usam metodologias conhecidas [Rajath and Vishwas Vivian 2026, Różycki et al. 2025, Bayoumi et al. 2026, Verdecchia et al. 2023, Marmouzi et al. 2026]. Dessa forma, os melhores dados vêm de operadores, que não são auditáveis; a economia de refrigeração é, em sua maioria, modelada ou de fornecedores [Alobid and Szűcs 2026]. Existem inconsistências internas e entre as revisões, como sentido invertido na comparação PyTorch e TensorFlow [Bayoumi et al. 2026, Verdecchia et al. 2023] e o peso relativo no treinamento e inferência [Rajath and Vishwas Vivian 2026]. Os *frameworks* propostos em [Lal and You 2025, Oliveira et al. 2026, Rojahn and Grum 2026] não foram validados de forma empírica.

6.3. Gargalos conceituais

Um dos problemas é o efeito rebote, que pode anular ganhos por tarefa [Khan et al. 2026, Lal and You 2025, Oliveira et al. 2026, Marmouzi et al. 2026]. Além disso, há o deslocamento de impacto, isto é, a energia de baixo carbono pode gerar o aumento na intensidade hídrica [Peykani et al. 2026, Alobid and Szűcs 2026], a borda desloca o consumo e a fabricação [Marmouzi et al. 2026], e o treinamento usando energia limpa para servir em rede fóssil gera ”vazamento de carbono” [Khan et al. 2026]. A maioria das técnicas utilizadas possui custos ocultos [Marmouzi et al. 2026, Peykani et al. 2026, Naser 2026], e o ganho operacional de hardware eficiente pode ser reduzido pelo carbono de fabricação [Khan et al. 2026, Marmouzi et al. 2026]. Existem também impedimentos práticos, como o alto investimento monetário e prazos longos para hardware [Khan et al. 2026], e falta na cobertura de água, materiais e no fim de vida [Marmouzi et al. 2026, Rojahn and Grum 2026, Alobid and Szűcs 2026].

7. Propostas Futuras

As propostas futuras estruturam-se em eixos de avaliação e mitigação. Na medição, em [Khan et al. 2026] e [Peykani et al. 2026] os autores recomendam relatos obrigatórios em camadas, enquanto em [Lal and You 2025] sugere-se a métrica de $kgCO_2e$ por hora de inferência. Em [Bayoumi et al. 2026] e [Rojahn and Grum 2026] destaca-se o uso de *benchmarks* e a calibração de estimadores contra medições físicas. Para o ciclo de vida, em [Khan et al. 2026, Verdecchia et al. 2023, Marmouzi et al. 2026, Frimpong 2025, Rojahn and Grum 2026] reforça-se o uso da ACV (ISO 14040/44) abrangendo fabricação, água e circularidade. Para viabilizar essas práticas, em [Khan et al. 2026, Verdecchia et al. 2023, Alobid and Szűcs 2026] os autores demandam estudos reprodutíveis, atribuição exata de ganhos, medições independentes de refrigeração e análises hídricas expandidas.

Em relação à governança, em [Frimpong 2025] os autores propõem certificações independentes e a divulgação auditada para modelos que ultrapassem 10^{18} FLOPs. Sugerem-se ainda tetos absolutos de emissão [Khan et al. 2026], limites para a retirada de água [Alobid and Szűcs 2026] e a adoção de orçamentos de sustentabilidade [Oliveira et al. 2026]. Na infraestrutura, em [Lal and You 2025] os autores propõem alinhar a expansão da IA às estratégias de descarbonização regional (priorizando renováveis e usando reatores modulares pequenos como complemento condicional), além de integrar a carga energética da IA aos modelos climáticos globais.

No nível operacional, em [Bayoumi et al. 2026] propõe-se automatizar a seleção de técnicas e incorporar o carbono como objetivo na Busca de Arquiteturas Neurais (NAS). Em [Peykani et al. 2026] e [Naser 2026] os autores recomendam *hardware* neuromórfico, computação em memória e modelos especializados por domínio. Em [Peykani et al. 2026] e [Rojahn and Grum 2026] reforça-se o agendamento de tarefas sensível às emissões de carbono e à disponibilidade de água. Por fim, em [Oliveira et al. 2026] introduz-se um modelo conceitual de aprendizado por reforço multiagente, cuja recompensa penaliza as emissões operacionais e as incorporadas.

8. Conclusão

As treze revisões sintetizam que o impacto ambiental da IA deve ser definido pelo ciclo de vida completo, medido com fronteiras declaradas e calibradas contra medições reais,

e reduzido por uma combinação de otimização técnica, gestão operacional e governança. Então deixamos de economizar energia para mostrar real redução. Como a base quantitativa ainda é frágil, uma alegação de redução só é robusta se demonstrar economia líquida, para tarefa e qualidade comparáveis, com infraestrutura, ciclo de vida e escala de uso incluídos [Rojahn and Grum 2026].

Referências

Alobid, M. and Szűcs, I. (2026). The water and energy footprint of artificial intelligence and its hardware: A comprehensive review. *Next Sustainability*.

Bayoumi, R., Nazmy, T., M. Salem, A.-B., and Hindy, H. (2026). A comprehensive review on green AI methods, strategies & measurement frameworks. *Journal of King Saud University - Computer and Information Sciences*.

Frimpong, V. (2025). What counts as green AI? mapping efficiency, sustainability, and critical-ecological strands in a fragmented discourse. *Qeios*.

Khan, N., Sikandar, H., Falahat, M., and Akhtar, N. (2026). The sustainability paradox: A systematic review of carbon footprints and decarbonization strategies for artificial intelligence in climate science. *Sustainable Environment*.

Lal, A. and You, F. (2025). Advances and challenges in energy and climate alignment of AI infrastructure expansion. *Advances in Applied Energy*.

Marmouzi, O., Oumaira, I., and Ajana El Khaddar, M. (2026). A systematic review of green and sustainable AI: Taxonomy, metrics, challenges, and open research directions. *Sustainability (Switzerland)*.

Naser, M. (2026). When machine learning models retire, decay, or become obsolete: A review on algorithms, software, and hardware. *Renewable and Sustainable Energy Reviews*.

Oliveira, A. P., Carraquico, T., and Martinez-Perez, C. (2026). Beyond efficiency: A systematic review of energy consumption and carbon footprint across the AI lifecycle. *Sustainability (Switzerland)*.

Peykani, P., Emrouznejad, A., Ghanidel, S., Javadi-Sisi, I., and Mirjalili, S. (2026). Green artificial intelligence: A comprehensive review of metrics, tools, challenges, trends, and future prospects. *Archives of Computational Methods in Engineering*.

Rajath, S. and Vishwas Vivian, A. (2026). Eco-conscious green AI: Reviewing sustainability approaches to minimize environmental impact. *Next Sustainability*.

Rojahn, M. and Grum, M. (2026). Green artificial intelligence and its lifecycle, hardware, and measurement dimensions. *Information and Software Technology*.

Rojek, I., Mikołajewski, D., Mroziński, A., and Macko, M. (2024). Green energy management in manufacturing based on demand prediction by artificial intelligence—a review. *Electronics (Switzerland)*.

Różycki, R., Solarska, D. A., and Waligóra, G. (2025). Energy-aware machine learning models—a review of recent techniques and perspectives. *Energies*.

Verdecchia, R., Sallou, J., and Cruz, L. (2023). A systematic review of green AI. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*.